



SAPIENZA
UNIVERSITÀ DI ROMA

Disambiguare il senso lessicale tra definizione e uso

Un approccio pragmatico alla Word Sense Disambiguation con LLM su risorse incrociate

Facoltà di Ingegneria dell'Informazione, Informatica e Statistica
Laurea Triennale in Informatica

Eva Evangelisti

Matricola 2066788

Relatore

Prof. Roberto Navigli

Anno Accademico 2025/2026

Tesi non ancora discussa

Disambiguare il senso lessicale tra definizione e uso

Tesi di Laurea Triennale. Sapienza Università di Roma

© 2026 Eva Evangelisti. Tutti i diritti riservati

Questa tesi è stata composta con $\text{\LaTeX}$ e la classe Sapthesis.

Email dell'autore: evangelisti.2066788@studenti.uniroma1.it

Ai miei genitori

Sommario

La Word Sense Disambiguation (WSD) individua il senso di una parola in un dato contesto, rispetto a un inventario di sensi. Gli inventari consolidati, come WordNet, raggruppano i sensi in classi ampie; Wiktionary registra distinzioni più fini e aggiornate, ma l'assenza di corpora annotati su larga scala limita il suo impiego. I Large Language Models disambiguano tramite la selezione della definizione appropriata, un compito metalinguistico distinto dall'uso della lingua. La tesi affronta entrambe le questioni: quattro dataset di valutazione per la lingua inglese, derivati dall'incrocio di frasi e inventari di sensi di Wiktionary e WordNet, misurano l'effetto della granularità semantica sulle prestazioni; un metodo di disambiguazione con continuazioni testuali, in cui il modello prolunga la frase prima della scelta del senso, riporta l'uso della lingua nel processo. La valutazione, condotta su due modelli open weight, mostra un peggioramento dell'accuratezza con le continuazioni, crescente con il vincolo sulla generazione. L'analisi qualitativa individua l'origine del peggioramento nella fase di selezione, incapace di sfruttare il segnale disambiguante della continuazione.

Ringraziamenti

Ringrazio il professor Roberto Navigli per avermi affidato un progetto di tesi affine ai miei interessi e per avermi orientata lungo il percorso. Sono inoltre grata ad Alessandro Cecchetto, NLP Engineer presso Babelscape, per l'esecuzione degli esperimenti in ambiente HPC.

Infine, grazie a chi mi è stato accanto, condividendo con me gioie e dolori di un periodo accademico intensamente vissuto.

Indice

1	Introduzione	1
1.1	Struttura della tesi	2
2	Word Sense Disambiguation: stato dell'arte	3
2.1	Risorse lessicali	4
2.1.1	Wiktionary	4
2.2	Approcci	4
2.2.1	Large Language Models	5
2.2.2	Valutazione	6
3	Integrazione di Wiktionary e WordNet	8
3.1	Estrazione dei dati da Wiktionary	8
3.2	Mappature	10
3.2.1	Glosse principali e glosse di traduzione	10
3.2.2	Glosse di Wiktionary e sensi di WordNet	10
3.3	Definizione dei dataset finali	11
4	Dalla definizione all'uso	13
4.1	Setup sperimentale	13
4.2	Disambiguazione diretta	14
4.2.1	Analisi degli errori	14
4.3	Disambiguazione con continuazioni	15
4.3.1	Generazione delle continuazioni	15
4.3.2	Integrazione delle continuazioni nella disambiguazione	17
5	Conclusioni	22
5.1	Limiti	22
5.2	Sviluppi futuri	23
A	Prompt	24
	Bibliografia	27

Capitolo 1

Introduzione

La parola inglese *bank* assume significati differenti nelle frasi seguenti:

1. *She deposited the money in the bank.*
2. *They walked along the bank of the river.*

In (1) *bank* denota un istituto finanziario, in (2) la riva di un fiume. Un parlante, guidato dalle parole vicine, seleziona il senso immediatamente. L'esempio non è isolato: l'ambiguità è una proprietà costitutiva delle lingue naturali.

Per una macchina è un compito esplicito, noto come Word Sense Disambiguation (WSD). Il compito richiede l'individuazione del senso di una parola in un dato contesto, rispetto a un inventario di sensi.

La scelta dell'inventario condiziona l'intero processo. Accanto a WordNet, riferimento consolidato della letteratura, Wiktionary offre distinzioni di senso più fini e vicine all'uso effettivo della lingua, ma resta ai margini della ricerca in mancanza di corpora annotati su larga scala. I Large Language Models affrontano la disambiguazione senza addestramento specifico, tramite la selezione della definizione più appropriata tra le candidate. Il paradigma presuppone però un giudizio esplicito sulla lingua. Da qui le due domande al centro della tesi: qual è l'effetto della granularità fine di Wiktionary sulla disambiguazione? Una prospettiva pragmatica può integrare il giudizio esplicito sul significato?

La tesi affronta le due domande con due contributi. Il primo è un insieme di quattro dataset per la valutazione della WSD in lingua inglese, costruiti dall'incrocio di frasi e inventari di sensi di Wiktionary e WordNet, per un totale di oltre 45.000 frasi annotate. Le combinazioni incrociate isolano il peso della granularità semantica sulle prestazioni. Il secondo è un metodo di disambiguazione con continuazioni testuali, in cui il modello prolunga la frase originale prima della scelta del senso. La valutazione sperimentale, condotta con due modelli open weight sui quattro dataset, misura l'effetto della granularità e analizza i limiti dell'approccio con continuazioni.

Il codice è disponibile pubblicamente in due repository: WSC¹, per l'estrazione dei dati di Wiktionary e la mappatura con WordNet, e CDE², per la disambiguazione.

¹<https://github.com/evaevangelisti/WSC>

²<https://github.com/evaevangelisti/CDE>

1.1 Struttura della tesi

Il Capitolo 2 ripercorre lo stato dell'arte della WSD, dalle risorse lessicali agli approcci di disambiguazione. Il Capitolo 3 descrive l'integrazione di Wiktionary e WordNet, e la definizione dei dataset. Il Capitolo 4 introduce e valuta la disambiguazione con continuazioni testuali. Il Capitolo 5 discute i risultati e delinea le prospettive future.

Capitolo 2

Word Sense Disambiguation: stato dell'arte

L'*indeterminatezza semantica*, intesa come possibilità di determinazioni plurime del significato di uno stesso morfo [7, p. 127], è una proprietà costitutiva delle lingue naturali. Tra le sue diverse manifestazioni, l'*ambiguità lessicale* e la *vaghezza* sono due fenomeni rilevanti per l'individuazione del senso di un lessema.

L'ambiguità lessicale emerge quando uno stesso significante è associato a due o più sensi discreti, la cui relazione reciproca determina la distinzione tra *polisemia* e *omonimia*. Nella polisemia i sensi sono correlati etimologicamente e semanticamente, mentre nell'omonimia sono del tutto indipendenti e la coincidenza formale è puramente accidentale.

Mentre l'ambiguità lessicale individua unità discrete, la vaghezza riguarda i *borderline cases*, ovvero contesti in cui l'applicazione di una forma lessicale risulta incerta. Se la tesi epistemica riconduce la vaghezza all'ignoranza dei confini netti dei concetti [26], una prospettiva diversa emerge dalla nozione wittgensteiniana di *somiglianze di famiglia* (*Familienähnlichkeit*) [27, §§ 66–67], secondo cui i membri di una categoria lessicale non condividono un insieme di proprietà necessarie e sufficienti, ma una complicata rete di somiglianze sovrapposte e intersecate.

Per i sistemi di elaborazione del linguaggio naturale, l'indeterminatezza semantica rappresenta una sfida non trascurabile. La Word Sense Disambiguation (WSD) è il processo di determinazione del senso di una parola in un dato contesto. Formalmente, sia w un lemma ambiguo e sia $S_D(w) = \{s_1, \dots, s_n\}$ l'insieme dei sensi a esso associati secondo una risorsa lessicale D . Dato un contesto c in cui w occorre, la WSD consiste nel definire una funzione:

$$f : (w, c) \rightarrow s_i \quad \text{con } s_i \in S_D(w)$$

che assegni a ogni occorrenza di w nel contesto c il senso s_i più appropriato.

La WSD presuppone alcune nozioni non esenti da criticità. Dizionari differenti adottano criteri di granularità divergenti nella partizione dei sensi, poiché ogni inventario riflette la politica editoriale e il pubblico di riferimento per cui è stato concepito [15, p. 100]. Più radicalmente, Kilgariff mette in discussione la nozione stessa di senso discreto: un repertorio di sensi indipendente dal compito applicativo

è un concetto privo di fondamento, in quanto i sensi esistono solo in relazione a un insieme di interessi e, in loro assenza, restano semplicemente indefiniti [15, p. 107].

Le sezioni seguenti esaminano i fondamenti della WSD: le risorse lessicali e gli approcci di disambiguazione.

2.1 Risorse lessicali

Le risorse lessicali costituiscono un presupposto fondamentale per qualsiasi sistema di WSD. I riferimenti più consolidati nella letteratura sono WordNet [19, 9] e BabelNet [21].

WordNet. WordNet è una base di dati lessicale dell'inglese in cui sostantivi, verbi, aggettivi e avverbi sono organizzati in insiemi di sinonimi cognitivi, detti *synset*, ciascuno dei quali esprime un concetto distinto. I synset sono interconnessi da relazioni semantiche e lessicali, secondo un'impostazione da tesaurus orientata alle relazioni tra parole distinte piuttosto che ai diversi significati della stessa parola, con una conseguente mancanza di rigore lessicografico [8, p. 281].

BabelNet. BabelNet nasce per superare i limiti di risorse monolingui come WordNet, integrando automaticamente conoscenza lessicografica ed enciclopedica attraverso l'allineamento di WordNet con Wikipedia.

2.1.1 Wiktionary

A differenza di WordNet, Wiktionary¹ è un dizionario multilingue collaborativo strutturato secondo il modello lessicografico tradizionale. Ogni voce è organizzata per etimologia e categoria grammaticale, e articolata in sensi numerati disposti secondo una gerarchia di accezioni principali e sottosensi. Ciascun senso è corredato di una definizione, di esempi d'uso costruiti e di citazioni tratte da testi reali che attestano l'uso del lessema. Le voci includono inoltre relazioni lessicali quali sinonimi, antonimi, iperonimi e iponimi, informazioni morfologiche e traduzioni nelle diverse lingue.

Per la natura collaborativa della risorsa, le distinzioni di senso riflettono l'uso effettivo della lingua e colgono sfumature semantiche e accezioni non sempre registrate da risorse costruite con criteri più restrittivi.

Nonostante il potenziale per la WSD, Wiktionary rimane marginale come inventario di sensi rispetto a WordNet e BabelNet, in parte per la minore standardizzazione della struttura delle voci e la conseguente difficoltà di estrazione automatica delle informazioni, in parte per l'assenza di corpora su larga scala annotati con i suoi sensi.

2.2 Approcci

La letteratura distingue tradizionalmente tre categorie di approcci [5]: supervisionati, basati sulla conoscenza e ibridi.

¹<https://www.wiktionary.org/>

Approcci supervisionati. Gli approcci supervisionati configurano la WSD come un problema di classificazione, addestrando modelli su corpora annotati con sensi (il più diffuso è SemCor [20]) per apprendere l’associazione tra parole in contesto e sensi. La baseline di riferimento è il senso più frequente (*Most Frequent Sense*, MFS), ovvero l’assegnazione a ogni lemma del significato predominante, indipendentemente dal contesto. A causa della distribuzione dei sensi fortemente sbilanciata, la baseline è rimasta a lungo difficile da superare. Con l’avvento delle architetture neurali basate su transformer [25], le prestazioni hanno superato la soglia dell’80% di accuratezza [5], oltrepassando i valori dell’MFS. Il traguardo appare significativo se confrontato con le difficoltà dell’accordo tra annotatori umani (*Inter-Annotator Agreement*) [22]. Il *knowledge-acquisition bottleneck* è il principale limite strutturale, dato dalla necessità di enormi volumi di dati annotati manualmente da esperti.

Approcci basati sulla conoscenza. Gli approcci basati sulla conoscenza (*knowledge-based*) non richiedono dati annotati, ma sfruttano le informazioni strutturate nelle risorse lessicali attraverso algoritmi di sovrapposizione lessicale, storicamente legati all’algoritmo di Lesk [17], o metodi *graph-based* applicati direttamente sulla struttura della rete semantica, come il *Personalized PageRank* [1]. Pur essendo più flessibili, raggiungono in genere risultati inferiori rispetto ai sistemi supervisionati [5].

Approcci ibridi. Gli approcci ibridi integrano reti semantiche con modelli neurali addestrati su dati annotati, e rappresentano lo stato dell’arte [5]. Sistemi come GlossBERT [14] affiancano le definizioni lessicali al contesto di occorrenza, mentre architetture successive come EWISER [4], ESC [2] e ConSeC [3] incorporano le relazioni dei grafi semantici negli spazi vettoriali dei transformer.

2.2.1 Large Language Models

Al di fuori della tassonomia tradizionale, i *Large Language Models* (LLM) sono modelli linguistici di grandi dimensioni basati sull’architettura transformer, addestrati su vasti corpora testuali. Rispetto ai modelli precedenti, vincolati a singoli compiti, gli LLM mostrano capacità generalizzate in molteplici domini, dalla comprensione e generazione del linguaggio naturale al ragionamento logico e alla traduzione automatica [6].

A differenza dei sistemi classici, l’applicazione degli LLM alla WSD non richiede necessariamente un addestramento supervisionato su corpora annotati: i modelli possono operare in modalità *zero-shot* o *few-shot*. Il processo adotta il paradigma dell’*In-Context Learning* strutturando il problema tramite *prompt engineering*. La letteratura recente delinea due approcci principali per l’implementazione della funzione f introdotta in precedenza: la selezione della definizione (*definition selection*) e la generazione della definizione (*definition generation*).

Selezione della definizione. La prima strategia riconduce il compito a un problema di *Question Answering*. Sia $G_D(w) = \{g_1, \dots, g_n\}$ l’insieme delle *glosse* associate ai rispettivi sensi $S_D(w)$ all’interno della risorsa lessicale D . Un template di prompt $\mathcal{P}$ mappa il lemma ambiguo w , il contesto c e l’inventario delle glosse $G_D(w)$ in una stringa testuale. La funzione di disambiguazione determina il senso corretto

stimando la probabilità condizionata assegnata dal modello al token identificativo (ad esempio l'indice dell'opzione) della definizione corretta:

$$f_{\text{LLM}}(w, c) = s_{\hat{i}} \quad \text{con } \hat{i} = \arg \max_{i \in \{1, \dots, n\}} P(\text{"Opzione } i" \mid \mathcal{P}(w, c, G_D(w)))$$

Generazione della definizione. La seconda strategia esclude l'uso di una lista predefinita nel prompt, affidando al modello la generazione di una glossa in linguaggio naturale $\hat{g} = \text{LLM}(\mathcal{P}(w, c))$ atta a descrivere il significato del lemma ambiguo w nel contesto c . La generazione libera descrive il senso in modo dinamico, in linea con la prospettiva di Kilgariff contro la rigidità di un inventario predefinito. Ricondurre la glossa generata all'inventario discreto della risorsa lessicale D richiede un confronto basato sulla similarità semantica. Siano $v_{\hat{g}}$ e v_{g_i} i vettori di embedding associati rispettivamente alla glossa generata e alle glosse candidate. La funzione individua il senso più vicino massimizzando la similarità del coseno:

$$f_{\text{LLM}}(w, c) = \arg \max_{s_i \in S_D(w)} \frac{v_{\hat{g}} \cdot v_{g_i}}{\|v_{\hat{g}}\| \|v_{g_i}\|}$$

In parallelo, l'analisi manuale permette di valutare qualitativamente la correttezza semantica delle glosse generate.

Nel paradigma di selezione della definizione, studi recenti documentano prestazioni paragonabili ai sistemi allo stato dell'arte, con una maggiore robustezza su domini diversi e su istanze difficili, sulle quali i modelli specializzati spesso falliscono [18].

Restano tuttavia limitazioni rilevanti. Le prestazioni peggiorano in presenza di sensi rari, i modelli mostrano sensibilità alla formulazione del prompt e all'ordine delle definizioni candidate, e il divario rispetto a un annotatore umano esperto è ancora ampio [18].

2.2.2 Valutazione

La valutazione della WSD assume due formulazioni principali. Nel compito *all words* il sistema disambigua tutte le parole di un testo, mentre nel *lexical sample* la disambiguazione riguarda un insieme ristretto di lemmi, valutati su numerose occorrenze.

I dataset di riferimento provengono dalle campagne di valutazione Senseval e, successivamente, SemEval, attive dagli anni 2000 con corpora annotati manualmente con i sensi di WordNet. La loro eterogeneità di formati e di versioni dell'inventario ha complicato a lungo il confronto diretto tra sistemi. Il framework unificato proposto da Raganato et al. [24] raccoglie i principali dataset all words in un formato comune, allineato a un'unica versione di WordNet, e rappresenta da allora il riferimento standard per la valutazione dei sistemi di WSD.

La metrica adottata è l'accuratezza, il rapporto tra le istanze disambiguate correttamente e il totale delle istanze:

$$\text{accuratezza} = \frac{|\text{istanze corrette}|}{|\text{istanze totali}|}$$

Quando la copertura del sistema è totale, ovvero ogni istanza riceve una predizione, l'accuratezza coincide con la misura F1:

$$F_1 = \frac{2PR}{P + R} = P = R = \text{accuratezza}$$

dove P è la precisione, il rapporto tra le predizioni corrette e quelle effettuate, e R è il richiamo, il rapporto tra le predizioni corrette e il totale delle istanze.

I benchmark consolidati restano limitati alla lingua inglese e all'inventario di WordNet. La valutazione su inventari a granularità diversa, come Wiktionary, è affrontata nei capitoli seguenti.

Capitolo 3

Integrazione di Wiktionary e WordNet

Come rilevato nel capitolo precedente, l'assenza di corpora annotati su larga scala rappresenta uno dei principali ostacoli all'impiego di Wiktionary nella WSD. Il dataset presentato nasce per colmare parzialmente la lacuna, e incrocia frasi e inventari di sensi di Wiktionary e WordNet: l'incrocio consente di valutare l'effetto della granularità semantica di Wiktionary sulle prestazioni dei modelli di disambiguazione. La costruzione procede in tre fasi: estrazione dei dati, mappature e definizione dei dataset finali.

3.1 Estrazione dei dati da Wiktionary

I dati in lingua inglese sono estratti con *wiktextract* [28]¹, uno strumento di parsing per convertire le voci del dizionario in dati strutturati. Per ciascuna voce sono raccolti il lemma, la categoria grammaticale, le glosse principali e le frasi di esempio costruite, oltre alle citazioni tratte da testi reali posteriori al 1900, utili ad attestare un uso della lingua sufficientemente recente, e alle glosse di traduzione con le rispettive traduzioni nelle diverse lingue. Nel seguito, il termine *frasi* indica sia le frasi di esempio sia le citazioni.

In Wiktionary, le traduzioni nelle diverse lingue sono associate a glosse distinte, tipicamente più brevi rispetto alle glosse principali e non direttamente allineate a esse. Il disallineamento strutturale rende le glosse di traduzione una fonte complementare, potenzialmente utile per cogliere descrizioni di senso alternative e più concise. La prima mappatura, descritta nella sezione successiva, le associa alle glosse principali.

La struttura gerarchica di Wiktionary, descritta nel capitolo precedente, solleva una questione di granularità, ovvero quali livelli includere come sensi distinti. La selezione ricade esclusivamente sulle glosse foglia, prive di sottosensi, poiché i nodi intermedi costituiscono un sovrainsieme, e il loro confronto non avrebbe significato semantico.

Per ciascuna frase è individuato l'intervallo testuale corrispondente al lemma, denominato *word offset*. L'individuazione combina due fonti: la lemmatizzazione con

¹<https://kaikki.org>

spaCy [12], basata sul modello `en_core_web_lg`, e l'attributo `bold_text_offsets` fornito da `wikitract`, contenente le posizioni del testo in grassetto nella frase. L'attributo non è tuttavia sempre presente e non coincide necessariamente con il lemma: la procedura di corrispondenza testuale e lemmatizzazione, formalizzata nell'Algoritmo 1, ricerca il lemma nella frase e accoglie i `bold_text_offsets` solo se anch'essi corrispondono al lemma. Poiché una stessa parola può occorrere più volte, ciascuna frase può essere associata a più word offset. Su 532.447 frasi totali, 477.871 sono associate ad almeno un word offset. La procedura è validata su un campione casuale di 100 frasi, tutte con word offset corretti.

Algorithm 1 Individuazione e validazione dei word offset.

Require: Frase Doc S , Lemma Doc L , Offset del testo in grassetto B

Ensure: Lista degli intervalli di offset validi Ω

```

1:  $\Omega \leftarrow []$ 
2:
3:  $L_{\text{testo}} \leftarrow$  testi dei token di  $L$  in minuscolo (esclusi spazi e trattini)
4:  $L_{\text{lemmi}} \leftarrow$  lemmi dei token di  $L$  in minuscolo (esclusi spazi e trattini)
5:
6: // Ricerca tramite finestra scorrevole sulla frase
7: for ogni posizione iniziale  $i$  nella frase  $S$  do
8:    $C \leftarrow$  i primi  $|L_{\text{testo}}|$  token da  $i$  in poi (esclusi spazi e trattini)
9:
10:   if  $|C| < |L_{\text{testo}}|$  then
11:     break
12:   end if
13:
14:   if i testi di  $C$  corrispondono a  $L_{\text{testo}}$  or i lemmi di  $C$  a  $L_{\text{lemmi}}$  then
15:     Aggiungi a  $\Omega$  gli offset di inizio e fine di  $C$ , se non presenti
16:   else if il testo del token in  $i$  corrisponde a  $L_{\text{testo}}$  unito or il suo lemma a  $L_{\text{lemmi}}$  unito then
17:     Aggiungi a  $\Omega$  gli offset del token, se non presenti
18:   end if
19: end for
20:
21: // Validazione e integrazione degli offset in grassetto
22: for ogni intervallo  $(start, end)$  in  $B$  do
23:    $V \leftarrow$  i token di  $S$  interamente contenuti tra  $start$  ed  $end$ 
24:    $V_{\text{testo}}, V_{\text{lemmi}} \leftarrow$  testi e lemmi di  $V$  in minuscolo (esclusi spazi e trattini)
25:
26:   if  $V_{\text{testo}}$  corrisponde a  $L_{\text{testo}}$  (anche unito) or  $V_{\text{lemmi}}$  a  $L_{\text{lemmi}}$  (anche unito) then
27:     Aggiungi  $(start, end)$  a  $\Omega$ , se non presente
28:   end if
29: end for
30:
31: return  $\Omega$ 

```

Il dataset grezzo comprende 1.251.542 record, ciascuno corrispondente a un lemma con categoria grammaticale, una lista di sensi e una lista di glosse di traduzione con le rispettive traduzioni. Ciascun senso è descritto dalla glossa principale, dalle glosse dei nodi intermedi nella gerarchia e dalle frasi associate, ognuna corredata dei word offset e dell'eventuale riferimento bibliografico. Delle 532.447 frasi, 108.229 sono frasi di esempio e 424.218 citazioni.

3.2 Mappature

Per collegare Wiktionary e WordNet sono condotte due mappature distinte, entrambe realizzate con gpt-oss-120b [23], un modello open weight, su un nodo HPC dotato di 4 GPU NVIDIA H100 e 32 CPU. L'inferenza sfrutta la libreria *vLLM* [16], configurata con un parallelismo tensoriale (`tensor_parallel_size`) di 4 e una lunghezza massima di generazione (`max_tokens`) pari a 2048 token. Gli altri parametri mantengono i valori predefiniti.

3.2.1 Glosse principali e glosse di traduzione

La prima mappatura associa le glosse principali alle glosse di traduzione di ciascun lemma, al fine di colmare il disallineamento strutturale descritto nella sezione precedente.

Il modello riceve in input le due liste di glosse e restituisce in formato JSON l'associazione tra ogni glossa principale e la glossa di traduzione corrispondente, o `null` in assenza di un equivalente semantico chiaro. Il prompt è riportato nella Tabella A.1.

Su 1.457.474 sensi totali, 156.510 sono mappati. La mappatura è validata su un campione casuale di 100 coppie, tutte corrette.

3.2.2 Glosse di Wiktionary e sensi di WordNet

La seconda mappatura collega le glosse di Wiktionary ai sensi di WordNet, per consentire il confronto tra i due inventari di sensi nella fase di valutazione.

La mappatura è condotta in modo bilaterale: ciascuna glossa principale di Wiktionary è associata al synset di WordNet più appropriato tra i candidati con lo stesso lemma e categoria grammaticale e, viceversa, ciascun synset alla glossa principale più appropriata. Il procedimento è applicato anche alle glosse di traduzione. Come nella prima mappatura, in assenza di un equivalente semantico chiaro il modello restituisce `null`. I prompt sono riportati nella Tabella A.2.

L'associazione finale tra Wiktionary e WordNet riguarda i soli sensi in cui le due direzioni concordano, con la mappatura tra glosse principali e glosse di traduzione come ponte tra le due coppie bilaterali.

In totale, 45.214 sensi sono mappati. I sensi non mappati riflettono le differenze di granularità semantica tra le due risorse. In linea generale, WordNet raggruppa i sensi in classi ampie. Al contrario, la natura collaborativa di Wiktionary favorisce la separazione delle sfumature di significato in sensi foglia distinti, strettamente legati a domini d'uso specifici e linguaggi settoriali. Il dizionario accoglie inoltre neologismi

e varianti colloquiali, spesso assenti in WordNet. La mappatura è validata su un campione casuale di 100 coppie, 96 corrette.

Analisi degli errori

I quattro errori emersi dalla validazione manuale sono riconducibili a un'unica causa, il disallineamento di ampiezza semantica tra glossa e synset.

In tre errori la glossa di Wiktionary è più ampia del synset selezionato. Per *indigo*, la glossa copre diversi generi e specie di piante, mentre il synset descrive unicamente la pianta dell'indaco. Analogamente, per *legume*, la definizione botanica estesa è ricondotta al solo synset relativo alle piante di fagiolo o pisello. Per *good* nell'accezione di «Effective», il modello seleziona il synset legato all'esercizio di una forza o influenza, più ristretto della glossa di partenza.

Nel quarto è invece il synset a essere più ampio. Per *powder*, l'accezione cosmetica di Wiktionary è associata a un synset esteso anche ai medicinali in polvere.

3.3 Definizione dei dataset finali

I dataset finali per la valutazione sono costruiti dal dataset grezzo e dalle mappature descritte nella sezione precedente. I sensi selezionati soddisfano tre requisiti: appartengono a lemmi con almeno due sensi distinti, condizione di effettiva ambiguità; sono associati ad almeno una frase con un word offset, in modo da rendere il lemma individuabile; sono mappati a un synset di WordNet, per consentire l'incrocio tra i due inventari di sensi.

Il formato originale, in cui ciascun record raggruppa tutti i sensi di un lemma, è trasformato in modo da associare ogni record finale a una frase con il relativo word offset. Le frasi con più word offset generano pertanto più record distinti. Un esempio di record in formato JSON è il seguente:

```
{
  "instance_id": "4ffa3e91-ada3-5ffd-9524-ed5ba54530f8.000001",
  "lemma": "free",
  "pos": "adj",
  "definitions": [...],
  "sense_id": "4ffa3e91-ada3-5ffd-9524-ed5ba54530f8.S18",
  "sense_index": 18,
  "sentence": "You can sit on this chair; it's free.",
  "word_offset": [32, 36]
}
```

Il campo `definitions` racchiude l'intero inventario dei sensi del lemma, mentre `sense_id` e `sense_index` identificano l'unica accezione corretta. Il campo `word_offset` delimita la posizione del lemma nella frase, con estremo destro escluso.

Le frasi di WordNet corrispondono agli esempi d'uso presenti nei singoli synset. I relativi word offset sono individuati con la stessa procedura di corrispondenza testuale e lemmatizzazione, senza il supporto dell'attributo `bold_text_offsets`, assente in WordNet.

Dalla combinazione di frasi e inventari di sensi derivano quattro dataset, identificati dalla notazione *Frase* $\times$ *Sensi*, dove il primo termine indica la risorsa di provenienza delle frasi e il secondo l’inventario di sensi adottato. Le due combinazioni incrociate consentono di valutare separatamente il contributo delle frasi e dell’inventario di sensi. La Tabella 3.1 riporta la composizione dei quattro dataset.

Dataset	Lemmi	Frase	Polisemia media
Wiktionary $\times$ Wiktionary	10.766	32.488	7,25
Wiktionary $\times$ WordNet	10.766	32.488	5,22
WordNet $\times$ Wiktionary	6.969	12.921	7,90
WordNet $\times$ WordNet	6.969	12.921	6,41

Tabella 3.1. Dataset finali.

A parità di frasi, l’inventario di Wiktionary presenta una polisemia media più alta rispetto a WordNet, a conferma della granularità più fine emersa dalla mappatura.

La Tabella 3.2 riporta la distribuzione delle categorie grammaticali dei lemmi per risorsa di provenienza delle frasi.

Risorsa	Sostantivi	Verbi	Aggettivi	Avverbi
Wiktionary	5.181 (48,12%)	2.378 (22,09%)	2.978 (27,66%)	229 (2,13%)
WordNet	2.005 (28,77%)	1.935 (27,77%)	2.801 (40,19%)	228 (3,27%)

Tabella 3.2. Distribuzione delle categorie grammaticali dei lemmi per risorsa.

La prevalenza dei sostantivi in Wiktionary è coerente con la natura collaborativa della risorsa, aperta a neologismi e vocaboli settoriali in prevalenza nominali.

I quattro dataset così definiti sono impiegati nel capitolo successivo per valutare e confrontare i modelli di disambiguazione.

Capitolo 4

Dalla definizione all'uso

Die Bedeutung eines Wortes ist sein
Gebrauch in der Sprache.

Ludwig Wittgenstein, *Philosophische
Untersuchungen*, § 43

La selezione della definizione, introdotta nel Capitolo 2 come paradigma di disambiguazione tramite LLM, richiede al modello un giudizio metalinguistico: un'affermazione esplicita sul significato di una parola, distinta dalla sua manifestazione nell'uso. Hu e Levy confrontano il prompting metalinguistico con la misurazione diretta delle probabilità assegnate dal modello e rilevano prestazioni generalmente inferiori nel primo approccio. L'accordo tra i due metodi diminuisce al crescere della distanza tra il prompt e la misurazione della probabilità della parola successiva [13]. Il fallimento di un modello in un compito metalinguistico non implica necessariamente l'assenza della relativa generalizzazione linguistica, bensì un'incapacità di accedere all'informazione rilevante e di manifestare la conoscenza posseduta in risposta a una domanda esplicita sulla lingua.

Valutare la disambiguazione anche attraverso l'uso concreto del linguaggio è coerente con la nozione wittgensteiniana di significato come uso [27, § 43], con la *distributional hypothesis* di Harris [11] e con l'affermazione di Firth, secondo cui il significato di una parola emerge dalla sua compagnia [10].

Il metodo proposto integra la prospettiva pragmatica nella disambiguazione e affianca alla selezione della definizione una fase di generazione testuale: il modello continua la frase originale, e la continuazione, in quanto atto linguistico, disambigua implicitamente il lemma prima della scelta esplicita del senso.

Il capitolo è articolato in tre sezioni, dedicate rispettivamente al setup sperimentale, alla disambiguazione diretta e alla disambiguazione con continuazioni.

4.1 Setup sperimentale

I modelli valutati sono gpt-oss-120b, un modello *mixture-of-experts* da 117 miliardi di parametri totali, di cui 5,1 attivi per token, e Gemma 4 31B, un modello denso da 31 miliardi di parametri. Il confronto permette di osservare l'effetto della scala e dell'architettura sulle prestazioni di disambiguazione.

Entrambi operano in modalità zero-shot, con temperatura pari a 0 nelle fasi di disambiguazione e a 0,4 nella generazione delle continuazioni, per favorire una generazione più naturale e variata. L’inferenza è eseguita con la stessa configurazione hardware e software impiegata per le mappature della Sezione 3.2.

La valutazione è condotta sui quattro dataset costruiti nel capitolo precedente. La metrica è l’accuratezza. Sono escluse le risposte non valide, ovvero prive di un indice di definizione riconducibile all’inventario di sensi proposto, risultate trascurabili in tutte le configurazioni.

4.2 Disambiguazione diretta

La disambiguazione diretta applica il paradigma di selezione della definizione e rappresenta la *baseline* del metodo proposto. Per ciascuna istanza, il modello riceve in input la frase e l’inventario di sensi del lemma e restituisce l’indice della definizione ritenuta più appropriata. Il prompt è riportato nella Tabella A.3.

La Tabella 4.1 riporta l’accuratezza ottenuta da ciascun modello sui quattro dataset.

Dataset	gpt-oss-120b	Gemma 4 31B
Wiktionary × Wiktionary	88,94%	89,98%
Wiktionary × WordNet	82,28%	83,21%
WordNet × Wiktionary	80,54%	81,13%
WordNet × WordNet	85,50%	88,68%
Media	84,32%	85,75%

Tabella 4.1. Accuratezza nella disambiguazione diretta

I due modelli raggiungono prestazioni simili su tutti i dataset, con Gemma 4 31B in leggero vantaggio. Il maggior numero di parametri totali di gpt-oss-120b non comporta quindi un beneficio sulla disambiguazione, mentre il divario nei parametri attivi per token è compatibile con il vantaggio del modello denso.

Le differenze maggiori riguardano invece i dataset. Le combinazioni native, in cui frasi e inventario di sensi provengono dalla stessa risorsa, superano da 5 a 8 punti percentuali le combinazioni incrociate. Una possibile spiegazione riconduce il divario alla natura delle risorse, poiché nelle combinazioni native le frasi di esempio sono scritte per illustrare le glosse del proprio inventario, mentre le combinazioni incrociate richiedono di allineare granularità semantiche differenti. Un riscontro proviene dalle frasi di Wiktionary, suddivise in esempi costruiti e citazioni. Gli esempi costruiti superano le citazioni da 1,5 a 2,8 punti percentuali con l’inventario di Wiktionary, mentre con l’inventario di WordNet la differenza è nulla.

4.2.1 Analisi degli errori

Gli errori sono analizzati manualmente a campione. I pattern emersi sono ricorrenti e comuni a modelli e dataset.

L'errore più frequente è la **confusione tra sensi affini**, in cui il modello seleziona un'accezione vicina al senso corretto e con definizione fortemente sovrapposta, difficile da distinguere anche per un annotatore umano.

Segue la **preferenza per il senso più frequente**, in cui il modello sceglie l'accezione più comune del lemma ignorando gli indizi contestuali.

Con minore frequenza emergono la **confusione tra letterale e figurato** e l'**interpretazione errata delle espressioni idiomatiche**, mentre errori sporadici interessano frasi dal contesto insufficiente, accezioni troppo ristrette e sensi sintatticamente incompatibili con la frase.

La Tabella 4.2 riporta un esempio per ciascuna delle quattro categorie principali.

Categoria	Frase	Senso corretto	Senso predetto
Confusione tra sensi affini	<i>deductive reasoning</i>	relating to logical deduction	involving inferences from general principles
Preferenza per il senso più frequente	<i>the whistle signalled the end of the game</i>	the act of signalling (e.g., summoning) by whistling or blowing a whistle	a small wind instrument that produces a whistling sound by blowing into it
Confusione tra letterale e figurato	<i>a bottomless pit</i>	Extremely deep.	Having no bottom.
Interpretazione errata delle espressioni idiomatiche	<i>fall by the wayside</i>	(intransitive) To collapse; to be overthrown or defeated.	(copulative, in idiomatic expressions) To become (chiefly used with negative states).

Tabella 4.2. Esempi di errori nella disambiguazione diretta.

4.3 Disambiguazione con continuazioni

Il metodo proposto procede in due fasi distinte: la generazione di una continuazione testuale della frase originale e l'integrazione della continuazione nella selezione della definizione.

4.3.1 Generazione delle continuazioni

Le continuazioni sono generate dallo stesso modello impiegato per la disambiguazione, secondo quattro condizioni con grado di vincolo crescente:

- **free**, in cui il modello continua liberamente il pensiero espresso dalla frase, senza alcun riferimento al lemma;

- **focused**, in cui la continuazione è orientata verso il lemma;
- **grounded**, in cui una breve proposizione radica la continuazione allo scenario specifico della frase;
- **constrained**, in cui la continuazione è limitata a un numero ridotto di parole ad alta densità terminologica, riferite al lemma.

I prompt corrispondenti sono riportati nella Tabella A.4.

In ciascuna condizione, il prompt richiede al modello di restituire la frase completa comprensiva della continuazione, anziché la sola continuazione. La richiesta permette lievi modifiche di raccordo tra la frase originale e la continuazione.

La procedura di validazione, formalizzata nell'Algoritmo 2, verifica la presenza della frase originale all'interno della continuazione tramite i blocchi di testo in comune, individuati con la classe `SequenceMatcher` della libreria standard di Python. Una continuazione è considerata valida quando i blocchi coprono, in ordine, oltre il 90% della frase originale. Il criterio è applicato anche alla variante della frase priva delle parti tra parentesi, frequenti negli esempi di WordNet. Le continuazioni non valide sono scartate e le relative istanze sono escluse dalla fase successiva.

Algorithm 2 Validazione della continuazione.

Require: Frase originale S , Continuazione generata C

Ensure: Vero se la continuazione è valida, Falso altrimenti

```

1:  $S \leftarrow$  normalizza  $S$  (minuscolo, spazi ai margini rimossi)
2:  $C \leftarrow$  normalizza  $C$  (minuscolo, spazi ai margini rimossi)
3:
4: if  $C$  è vuota or  $|C| \leq |S|$  then
5:   return Falso
6: end if
7:
8: for ogni variante  $V \in \{S, S \text{ senza parti tra parentesi}\}$  do
9:    $B \leftarrow$  blocchi di testo in comune tra  $V$  e  $C$ , in ordine
10:   $m \leftarrow$  somma delle lunghezze dei blocchi in  $B$ 
11:
12:   if  $m/|V| > 0,90$  then
13:     return Vero
14:   end if
15: end for
16:
17: return Falso

```

La Tabella 4.3 riporta la percentuale di continuazioni valide per modello, condizione e risorsa di provenienza delle frasi.

gpt-oss-120b				
Frase	Free	Focused	Grounded	Constrained
Wiktionary	84,08%	87,06%	88,03%	89,11%
WordNet	99,69%	99,61%	99,67%	98,92%

Gemma 4 31B				
Frase	Free	Focused	Grounded	Constrained
Wiktionary	90,21%	85,07%	77,56%	80,00%
WordNet	99,83%	99,84%	98,90%	99,47%

Tabella 4.3. Percentuale di continuazioni valide per modello, condizione e risorsa di provenienza delle frasi.

Analisi delle continuazioni non valide

Le continuazioni scartate, esaminate a campione, sono riconducibili a pattern ricorrenti.

Il più frequente è la **riscrittura della frase**, con parafrasi, sostituzioni di parole o completamenti delle ellissi dell'originale. La riscrittura è concentrata nella condizione constrained, dove le parole ad alta densità terminologica sostituiscono spesso la parte finale della frase anziché estenderla.

Segue la **ripresa parziale**, in cui la continuazione riparte da una porzione della frase originale, tipicamente l'ultimo periodo contenente il lemma, e omette l'inizio.

Con minore frequenza compaiono **continuazioni prive della frase originale** e **output identici alla frase**. Più raramente, negli esempi di WordNet, il modello continua il testo tra parentesi anziché la frase, e la procedura di validazione non prevede una variante corrispondente.

Emergono infine **rifiuti di generazione**, osservati solo in gpt-oss-120b su frasi dal contenuto sensibile, e sporadiche degenerazioni ripetitive.

I pattern dipendono dalla risorsa di provenienza delle frasi. Sulle frasi di Wiktionary, spesso lunghe e composte da più periodi, prevale la ripresa parziale; sulle frasi di WordNet, brevi e ricche di notazioni lessicografiche, prevale la riscrittura.

4.3.2 Integrazione delle continuazioni nella disambiguazione

Il prompt di disambiguazione affianca alla frase originale la continuazione validata nella fase precedente e richiede al modello di considerare entrambe nella scelta della definizione corretta. Il prompt è riportato nella Tabella A.5.

La Tabella 4.4 riporta l'accuratezza di ciascun modello per ciascuna condizione, confrontata con la baseline della disambiguazione diretta. Poiché ogni condizione esclude istanze diverse, la baseline è ricalcolata in ogni condizione sulle sole istanze con continuazione valida, in modo da confrontare i due metodi sulle stesse istanze. Per Gemma 4 31B la valutazione con continuazioni è disponibile sui soli dataset con frasi da Wiktionary.

Dataset	gpt-oss-120b							
	Free		Focused		Grounded		Constrained	
	D	C	D	C	D	C	D	C
Wiktionary × Wiktionary	89,12%	87,70%	89,09%	86,22%	89,15%	86,56%	89,17%	84,99%
Wiktionary × WordNet	82,52%	81,34%	82,43%	79,86%	82,46%	80,32%	82,43%	79,20%
WordNet × Wiktionary	80,55%	78,95%	80,56%	77,67%	80,53%	78,43%	80,51%	76,63%
WordNet × WordNet	85,50%	84,57%	85,51%	83,07%	85,50%	83,78%	85,50%	81,80%
Media	84,42%	83,14%	84,40%	81,71%	84,41%	82,27%	84,40%	80,66%

Dataset	Gemma 4 31B							
	Free		Focused		Grounded		Constrained	
	D	C	D	C	D	C	D	C
Wiktionary × Wiktionary	90,34%	90,20%	90,60%	90,47%	90,76%	90,57%	90,65%	89,24%
Wiktionary × WordNet	83,64%	83,31%	83,67%	83,28%	83,84%	83,32%	83,67%	82,60%
Media	86,99%	86,76%	87,14%	86,88%	87,05%	86,95%	87,16%	85,92%

Tabella 4.4. Accuratezza nella disambiguazione diretta (D) e con continuazione (C), per modello, condizione e dataset.

Per gpt-oss-120b, l'accuratezza con continuazione resta inferiore alla disambiguazione diretta in ogni condizione e su ogni dataset. Il peggioramento cresce con il grado di vincolo sulla generazione, dalla condizione free alla condizione constrained.

Sui dataset con frasi da Wiktionary, il peggioramento di Gemma 4 31B è minimo rispetto a gpt-oss-120b. La continuazione incide poco sull'accuratezza, tranne nella condizione constrained. Il modello denso appare quindi meno sensibile alla continuazione rispetto al modello mixture-of-experts.

Il peggioramento risulta da due esiti contrari. La continuazione rende errate alcune istanze corrette nella disambiguazione diretta, e corrette alcune istanze errate. La Tabella 4.5 riporta la percentuale dei due esiti, i *flip* negativi (N) e positivi (P). Per costruzione, la differenza tra flip positivi e negativi corrisponde allo scarto di accuratezza.

Dataset	gpt-oss-120b							
	Free		Focused		Grounded		Constrained	
	P	N	P	N	P	N	P	N
Wiktionary × Wiktionary	2,79%	4,21%	2,94%	5,81%	2,69%	5,28%	2,91%	7,09%
Wiktionary × WordNet	3,72%	4,89%	3,55%	6,12%	3,77%	5,91%	3,97%	7,20%
WordNet × Wiktionary	3,55%	5,15%	3,52%	6,41%	3,64%	5,75%	3,89%	7,77%
WordNet × WordNet	3,95%	4,88%	3,83%	6,27%	3,99%	5,72%	3,99%	7,69%
Media	3,50%	4,78%	3,46%	6,15%	3,52%	5,66%	3,69%	7,44%

Dataset	Gemma 4 31B							
	Free		Focused		Grounded		Constrained	
	P	N	P	N	P	N	P	N
Wiktionary × Wiktionary	2,74%	2,93%	2,85%	3,02%	2,91%	3,14%	2,95%	4,40%
Wiktionary × WordNet	3,03%	3,45%	3,21%	3,69%	3,24%	3,86%	3,45%	4,62%
Media	2,89%	3,19%	3,03%	3,36%	3,08%	3,50%	3,20%	4,51%

Tabella 4.5. Percentuale di flip positivi (P) e negativi (N) tra disambiguazione diretta e con continuazione, per modello, condizione e dataset.

Per gpt-oss-120b, i flip positivi restano pressoché costanti, mentre i flip negativi crescono con il grado di vincolo, dalla condizione free alla condizione constrained. Il peggioramento è di entità simile sui dataset nativi e incrociati, e lascia inalterato il divario tra le due tipologie osservato nella disambiguazione diretta. L'effetto della continuazione non dipende quindi dalla risorsa di provenienza delle frasi né dall'inventario di sensi, ma dal metodo in sé.

Per Gemma 4 31B, sui dataset con frasi da Wiktionary, i flip positivi e negativi restano ridotti e simili tra loro, e la loro differenza cresce solo nella condizione constrained.

La Figura 4.1 riporta l'accuratezza per lunghezza della frase, misurata in parole, per i due modelli.




Figura 4.1. Accuratezza per lunghezza della frase

L'accuratezza è più bassa sulle frasi brevi, in entrambi i metodi, per via del contesto ridotto disponibile alla disambiguazione. Lo scarto tra disambiguazione diretta e con continuazione resta però simile a ogni lunghezza. Per Gemma 4 31B le due curve restano vicine, a conferma della minore sensibilità del modello alla continuazione.

Analisi dei flip

I flip sono analizzati manualmente su un campione bilanciato tra flip positivi e negativi. L'analisi distingue i pattern all'origine dei due tipi.

Nei flip positivi prevale la **disambiguazione tramite contesto**, in cui la continuazione esplicita lo scenario d'uso implicito nella frase originale e orienta la selezione verso il senso corretto. Il pattern ricorre soprattutto su frasi brevi e decontestualizzate, dove il contesto iniziale è insufficiente. Con minore frequenza emergono la **specificazione del dominio**, in cui la continuazione rende esplicito

un ambito tecnico o settoriale, e la **correzione del senso più frequente**, in cui la continuazione sposta la selezione dall’accezione più comune a quella appropriata.

Nei flip negativi prevale lo **slittamento verso un senso affine**, in cui la continuazione resta plausibile ma sposta la selezione verso un’accezione vicina e più generica o più specifica del senso corretto. Segue la **continuazione fuorviante**, in cui la generazione introduce elementi coerenti con un senso diverso e allontana la selezione dal senso della frase originale. Con minore frequenza compare la **deriva terminologica**, concentrata nella condizione constrained, dove le parole ad alta densità terminologica introducono un registro tecnico e orientano la selezione verso un’accezione specialistica estranea al contesto.

La Tabella 4.6 riporta un esempio per ciascuna delle categorie principali.

Categoria	Frase	Continuazione	Senso corretto	Senso predetto
Disambiguazione tramite contesto	<i>a lofty goal</i>	<i>A lofty goal requires a practical plan.</i>	Idealistic, implying over-optimism	Idealistic, implying over-optimism
Specificazione del dominio	<i>a nest of snipers</i>	<i>A nest of snipers maintaining interlocking fields of fire.</i>	a kind of gun emplacement	a kind of gun emplacement
Correzione del senso più frequente	<i>our accountant is thorough</i>	<i>Our accountant is thorough, double-checking every entry.</i>	painstakingly careful and accurate	painstakingly careful and accurate
Slittamento verso un senso affine	<i>distinguished jurist</i>	<i>The distinguished jurist presided over the high court.</i>	legal scholar	public official who decides in court
Continuazione fuorviante	<i>the celebration of marriage</i>	<i>The celebration of marriage, held in the garden as the sun set, brought together family and friends.</i>	formal performance of a solemn rite	social gathering, a party
Deriva terminologica	<i>a smart outfit</i>	<i>a smart outfit integrated IoT sensors.</i>	elegant and stylish	capable of intelligent action

Tabella 4.6. Esempio di flip per ciascuna categoria.

Valutazione qualitativa delle continuazioni

Le continuazioni sono valutate manualmente a campione. A ciascuna è assegnato un punteggio per l’effetto sulla disambiguazione della continuazione generata rispetto alla frase originale:

- +1 quando la continuazione orienta verso il senso corretto;
- 0 quando lascia invariata l’ambiguità;
- −1 quando orienta verso un senso errato.

Il punteggio riguarda la continuazione, indipendentemente dalla definizione selezionata dal modello.

La continuazione orienta perlopiù verso il senso corretto. Spesso non aggiunge invece elementi utili alla disambiguazione. Raramente orienta verso un senso errato. La condizione *constrained* fa eccezione, con continuazioni meno efficaci nella disambiguazione.

Il risultato dell'analisi qualitativa è in contrasto con il peggioramento osservato nella disambiguazione con continuazioni. Il segnale disambiguante nel testo generato non conduce a una selezione corretta, e la selezione resta il punto critico del metodo.

Capitolo 5

Conclusioni

La tesi affronta la Word Sense Disambiguation tra due poli, la definizione e l'uso, con un contributo per ciascuno.

Il primo contributo è un insieme di quattro dataset di valutazione, derivati dall'incrocio di frasi e inventari di sensi di Wiktionary e WordNet, in cui le combinazioni incrociate isolano l'effetto della granularità semantica. La granularità più fine di Wiktionary emerge dalla polisemia media più alta rispetto a WordNet e dal divario di accuratezza tra combinazioni native e incrociate nella disambiguazione diretta, a conferma della distanza tra i due inventari.

Il secondo contributo è un metodo di disambiguazione con continuazioni testuali, in cui una fase di generazione affianca la selezione della definizione, con l'obiettivo di coinvolgere l'uso della lingua nel processo. La valutazione mostra un peggioramento dell'accuratezza rispetto alla disambiguazione diretta, crescente con il grado di vincolo sulla generazione. Il peggioramento riguarda entrambi i modelli, con un effetto più marcato su gpt-oss-120b.

Secondo l'analisi qualitativa, la prospettiva pragmatica muove nella direzione giusta, ma la disambiguazione conserva le criticità della task di selezione di una definizione. La contraddizione emersa indica la necessità di approfondire ulteriormente il rapporto tra la definizione e l'uso nei modelli linguistici.

5.1 Limiti

La valutazione considera due soli modelli, insufficienti a distinguere gli effetti della scala e dell'architettura. gpt-oss-120b e Gemma 4 31B differiscono per numero di parametri e per struttura, e non è possibile attribuire le differenze osservate a una sola delle due dimensioni.

I dati e la valutazione coprono soltanto la lingua inglese. Le glosse di traduzione estratte da Wiktionary offrono un aggancio ad altre lingue, ma restano troppo frammentarie per sostenere una valutazione multilingue.

L'analisi qualitativa è condotta su campioni ridotti, adeguati a individuare i pattern ricorrenti ma non a stimare la loro frequenza. Inoltre, fenomeni più rari potrebbero sfuggire all'analisi.

Le annotazioni sono manuali e non seguono un metodo rigoroso. Riflettono il giudizio di un solo annotatore.

Alcune prove preliminari hanno evidenziato una sensibilità delle prestazioni alla formulazione dei prompt, sebbene non sia stata effettuata un'ottimizzazione rigorosa. Un diverso fraseggio delle istruzioni o un diverso ordine delle definizioni candidate potrebbero modificare i risultati.

I dataset includono, accanto a occorrenze reali, frasi di esempio costruite, meno rappresentative dell'uso linguistico effettivo. Le frasi costruite, redatte per illustrare un senso, lo rendono più riconoscibile rispetto alle occorrenze reali, e possono così agevolare la disambiguazione.

5.2 Sviluppi futuri

I dataset presentati permettono la valutazione, ma l'addestramento su Wiktionary richiede corpora annotati su larga scala. La loro assenza è l'ostacolo iniziale della tesi, e la loro costruzione resta uno sviluppo aperto.

La valutazione può essere estesa ad altre lingue, in particolare dove le risorse sono limitate. Per la sua natura collaborativa e multilingue, Wiktionary copre lingue prive di inventari consolidati e offre una granularità di senso altrimenti assente. Anche su Wiktionary, però, le lingue meno diffuse sono meno coperte.

Il metodo con continuazioni genera e valuta il senso con lo stesso modello. Un'architettura a due livelli, in cui un modello genera la continuazione e un altro seleziona la definizione, meriterebbe di essere esplorata.

Un'ultima direzione riguarda il superamento dei sensi discreti, al centro della critica di Kilgarriff. La disambiguazione rimane ancorata a un inventario predefinito, mentre il significato di una parola nell'uso è sfumato. Rappresentazioni continue del significato, sostenute dalla capacità generativa dei modelli linguistici, potrebbero descrivere il senso senza ridurlo a una scelta tra unità date.

Appendice A

Prompt

La presente appendice riporta i template dei prompt utilizzati nei capitoli precedenti.

Il prompt per la mappatura tra glosse principali e glosse di traduzione è riportato nella Tabella A.1, mentre i prompt per le mappature tra Wiktionary e WordNet sono riportati nella Tabella A.2.

Il prompt per la disambiguazione diretta è riportato nella Tabella A.3. I prompt per la generazione delle continuazioni nelle quattro condizioni sono riportati nella Tabella A.4, mentre il prompt per la disambiguazione con continuazione è riportato nella Tabella A.5.

Given these full definitions of the word "<lemma>":

<main_glosses>

Associate them with the following short definitions:

<translation_glosses>

Return a JSON object where:

- Keys are full definition numbers IDs (e.g., "F1", "F2", "F3")
- Values are short definition IDs (e.g., "S1", "S2")

Constraints:

- Each short definition ID can be used only once
- Do not infer or force associations
- Use null if there is no clear semantic equivalent

Output:

Return only a minified JSON string (no markdown formatting, no explanations)

Tabella A.1. Prompt per la mappatura tra glosse principali e glosse di traduzione.

Wiktionary a WordNet

Given this definition from Wiktionary for the word `<lemma>`:

`<wiktionary_gloss>`

Associate it with the following definitions from WordNet (each with its synonyms):

`<wordnet_senses>`

Constraints:

- Do not infer or force associations
- Return null if there is no clear semantic equivalent

Output:

Return only the synset ID as a string (e.g., "dog.n.01", "cat.n.02") or null (no markdown formatting, no explanations)

WordNet a Wiktionary

Given this definition from WordNet for the word `<lemma>`:

`<wordnet_sense>`

Associate it with the following definitions from Wiktionary:

`<wiktionary_glosses>`

Constraints:

- Do not infer or force associations
- Return null if there is no clear semantic equivalent

Output:

Return only the definition number as an integer (e.g., 1, 2, 3) or null (no markdown formatting, no explanations)

Tabella A.2. Prompt per le mappature tra Wiktionary e WordNet.

Read the sentence: `<sentence>`

Choose the correct dictionary definition of the word "`<word>`":

`<definitions>`

Provide as output only the number of the correct definition.

Tabella A.3. Prompt per la disambiguazione diretta.

Condizione	Prompt
Free	Given the following sentence, naturally continue the thought: <sentence> Provide the complete sentence with the continuation, without explanations or formatting.
Focused	Given the following sentence, focus on the word <word> and naturally continue the thought: <sentence> Provide the complete sentence with the continuation, without explanations or formatting.
Grounded	Given the following sentence, focus on the word <word> and continue the thought by adding a brief clause that grounds that specific scenario: <sentence> Provide the complete sentence with the continuation, without explanations or formatting.
Constrained	Given the following sentence, focus on the word <word> and complete the thought by adding only 3 to 5 terminology-dense words that naturally extend that specific aspect: <sentence> Provide the complete sentence with the continuation, without explanations or formatting.

Tabella A.4. Prompt per la generazione delle continuazioni nelle quattro condizioni.

Read the sentence: **<sentence>**
The following continuation implicitly disambiguates the word **<word>**:
<continuation>

Based on both the sentence and the continuation, choose the correct dictionary definition of the word **<word>**:
<definitions>

Provide as output only the number of the correct definition.

Tabella A.5. Prompt per la disambiguazione con continuazione.

Bibliografia

- [1] AGIRRE, E. AND SOROA, A. Personalizing pagerank for word sense disambiguation. In *Proceedings of the 12th Conference of the European Chapter of the ACL (EACL 2009)* (2009).
- [2] BARBA, E., PASINI, T., AND NAVIGLI, R. Esc: Redesigning wsd with extractive sense comprehension. In *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies* (2021).
- [3] BARBA, E., PROCOPIO, L., AND NAVIGLI, R. Consec: Word sense disambiguation as continuous sense comprehension. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing* (2021).
- [4] BEVILACQUA, M. AND NAVIGLI, R. Breaking through the 80% glass ceiling: Raising the state of the art in word sense disambiguation by incorporating knowledge graph information. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics* (2020).
- [5] BEVILACQUA, M., PASINI, T., RAGANATO, A., AND NAVIGLI, R. Recent trends in word sense disambiguation: A survey. In *Proceedings of the Thirtieth International Joint Conference on Artificial Intelligence, IJCAI-21* (2021).
- [6] CHANG, Y., ET AL. A survey on evaluation of large language models. *ACM Trans. Intell. Syst. Technol.*, (2024).
- [7] DE MAURO, T. *Lezioni di linguistica teorica*. Laterza (2008).
- [8] EDMONDS, P. AND KILGARRIFF, A. Introduction to the special issue on evaluating word sense disambiguation systems. *Natural Language Engineering*, (2002).
- [9] FELLBAUM, C. (ed.). *WordNet: An Electronic Lexical Database*. The MIT Press (1998).
- [10] FIRTH, J. R. A synopsis of linguistic theory, 1930–1955. In *Studies in Linguistic Analysis* (1957).
- [11] HARRIS, Z. S. Distributional structure. *WORD*, (1954).
- [12] HONNIBAL, M., MONTANI, I., VAN LANDEGHEM, S., AND BOYD, A. spacy: Industrial-strength natural language processing in python. (2020).

- [13] HU, J. AND LEVY, R. Prompting is not a substitute for probability measurements in large language models (2023).
- [14] HUANG, L., SUN, C., QIU, X., AND HUANG, X. Glossbert: Bert for word sense disambiguation with gloss knowledge. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)* (2019).
- [15] KILGARRIFF, A. I don't believe in word senses. *Computers and the Humanities*, (1997).
- [16] KWON, W., LI, Z., ZHUANG, S., SHENG, Y., ZHENG, L., YU, C. H., GONZALEZ, J. E., ZHANG, H., AND STOICA, I. Efficient memory management for large language model serving with pagedattention. In *Proceedings of the ACM SIGOPS 29th Symposium on Operating Systems Principles* (2023).
- [17] LESK, M. Automatic sense disambiguation using machine readable dictionaries: how to tell a pine cone from an ice cream cone. In *Proceedings of the 5th Annual International Conference on Systems Documentation* (1986).
- [18] MECONI, D., STIRPE, S., MARTELLI, F., LAVALLE, L., AND NAVIGLI, R. Do large language models understand word senses? In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing* (2025).
- [19] MILLER, G. A. Wordnet: a lexical database for english. *Commun. ACM*, (1995).
- [20] MILLER, G. A., LEACOCK, C., TENGI, R., AND BUNKER, R. T. A semantic concordance. In *Human Language Technology: Proceedings of a Workshop Held at Plainsboro, New Jersey, March 21-24, 1993* (1993).
- [21] NAVIGLI, R. AND PONZETTO, S. P. Babelnet: Building a very large multilingual semantic network. In *Proceedings of the 48th Annual Meeting of the Association for Computational Linguistics* (2010).
- [22] NG, H. T., LIM, C. Y., AND FOO, S. K. A case study on inter-annotator agreement for word sense disambiguation. In *SIGLEX99: Standardizing Lexical Resources* (1999).
- [23] OPENAI. gpt-oss-120b & gpt-oss-20b model card (2025).
- [24] RAGANATO, A., CAMACHO-COLLADOS, J., AND NAVIGLI, R. Word sense disambiguation: A unified evaluation framework and empirical comparison. In *Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics: Volume 1, Long Papers* (2017).
- [25] VASWANI, A., SHAZEER, N., PARMAR, N., USZKOREIT, J., JONES, L., GOMEZ, A. N., KAISER, L., AND POLOSUKHIN, I. Attention is all you need. *CoRR*, (2017).
- [26] WILLIAMSON, T. *Vagueness*. Routledge (1994).

-
- [27] WITTGENSTEIN, L. *Philosophische Untersuchungen*. Blackwell (1953).
- [28] YLONEN, T. Wiktextextract: Wiktionary as machine-readable structured data. In *Proceedings of the Thirteenth Language Resources and Evaluation Conference* (2022).